MACHINE LEARNING CANVAS

Designed for: Sistema de bicicleta publica MiBici (AMG) Designed by: Equipo 32 (Rolando, Johanna, Alejandro, Gerardo) Date: 17/10/2026 Iteration: 1.

PREDICTION TASK

P1 (regresion): predecir el numero de viajes iniciados por estacion por dia.

P2 (clasificacion binaria): estacion en riesgo de quedar sin bicicletas o sin anclajes en la franja siguiente.

P3 (clustering): agrupar las 484 estaciones por patron de uso (KMeans k=4; candidato aglomerativo). Sin resultado observado: validacion por estabilidad temporal.

DECISIONS

Operador del sistema: dimensiona flota y turnos segun la demanda prevista por estacion (P1).

Equipo de rebalanceo: prioriza que estaciones visitar en el dia, segun la lista de estaciones en riesgo (P2).

Planeacion urbana: ubica nuevas estaciones segun los grupos de uso identificados (P3).

VALUE PROPOSITION

Beneficiario: la operacion de MiBici (AMG) y, en ultima instancia, el usuario que siempre encuentra bici y anclaje.

Dolores: viajes perdidos por estaciones vacias/saturadas, rebalanceo reactivo y expansion sin evidencia.

Integracion: reporte batch diario (pronostico + lista de riesgo) para el operador; analisis trimestral de clusters para planeacion. A futuro, servicio via API.

DATA COLLECTION

Ingesta automatizada y reproducible: python -m mibici.dataset descarga, normaliza (columnas, encoding, fechas) y guarda Parquet.

Actualizacion: agregar la URL del nuevo mes a config.py y re-ejecutar; descarga idempotente (no repite lo ya bajado).

Version de datos: manifiesto con SHA-256 por archivo (data_version 7aa5e436d887), registrado en cada run de MLflow.

DATA SOURCES

Portal de datos abiertos de MiBici: viajes mensuales en CSV (ene-dic 2025: 4,532,032 viajes).

Nomenclatura de estaciones: id, nombre, latitud/longitud y capacidad (484 estaciones).

Datos publicos; sin datos personales mas alla de genero y anio de nacimiento, que se usan de forma agregada.

IMPACT SIMULATION

Costo de no detectar una estacion vacia/saturada: viajes perdidos en esa franja. Costo de falsa alarma: visita innecesaria del equipo de rebalanceo. El balance define el umbral de P2 (priorizar recall si la visita es barata).

Simulacion pre-despliegue: particion temporal train ene-oct / test nov-dic 2025 (sin fuga del futuro).

Criterio de despliegue: superar al baseline en la metrica de cada pregunta.

Equidad: revisar que el error no se concentre en zonas perifericas.

MAKING PREDICTIONS

Batch diario (madrugada): pronostico de demanda (P1) y lista de estaciones en riesgo (P2). Tiempo disponible: horas; recursos modestos (CPU).

P3 se recalcula trimestralmente para planeacion.

Featurizacion incluida en el pipeline (mismas funciones de features.py en entrenamiento y prediccion).

BUILDING MODELS

3 modelos en produccion: uno por pregunta.

Reentrenamiento mensual al publicarse el nuevo mes de datos (re-ejecucion del pipeline; horas de CPU).

Cada entrenamiento queda registrado en MLflow (experimento mibici-equipo32) con parametros, metricas, git_commit y data_version.

FEATURES

Agregados por estacion y ventana: salidas, llegadas, flujo neto.

Calendario: dia de semana, mes, hora; perfil horario (pico AM/PM).

Capacidad de la estacion (nomenclatura).

Rezagos e historial reciente, sin informacion posterior al momento de la prediccion.

Implementadas como funciones documentadas en mibici/features.py.

MONITORING

Error rodante: prediccion vs. demanda real del dia siguiente (P1).

% de alertas de riesgo que resultaron correctas y viajes perdidos evitados (P2).

Estabilidad de clusters entre trimestres (P3).

Data drift con Evidently y reentrenamiento al detectarlo (Continuous Training, modulo 3). Revision mensual.



Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO